Objectif

Le but de ce projet est de construire un moteur de recherche en Java, utilisable à la fois en ligne de commande et via une interface web.

À terme, ce moteur devra délivrer des résultats pertinents en un temps raisonnable sur un site web de taille relativement important (10 000 à 50 000 pages).

Le contenu francophone de Wikipédia étant trop vaste pour ce projet, nous nous rabattrons sur la version francophone de Vikidia, qui est une version de Wikipedia destinée aux enfants. Il contient environ 45 000 articles relativement courts, ce qui est un objectif raisonnable.

Principe de fonctionnement

Nous reprendrons le **modèle vectoriel** exposé précédemment.

?

Chaque page est donc découpée en mots, et la recherche s'effectue en comparant les mots cherchés et les mots de la page (d'un point de vue mathématique, on mesure l'écart angulaire entre les deux vecteurs, comme expliqué dans la présentation que vous avez lu la 1re semaine).

C'est donc un modèle relativement simple, qui ne tient pas compte de l'agencement des mots dans le texte (par exemple, si je cherche *animal roux*, notre modèle ne permet pas de privilégier les pages où les deux mots se suivent directement).

L'implémentation d'un moteur de recherche nécessite deux étapes :

1. Une indexation *à froid* des pages web.
2. Une comparaison *à chaud* du contenu des pages indexées et de la requête effectuée.

Détaillons un peu...

L'indexation (*à froid*)

Extraire en temps réel lors d'une recherche le contenu de toutes les pages web à indexer serait beaucoup trop long.

On effectue donc, **en amont de la recherche**, une indexation *à froid* :

1. Le contenu de chaque page web est récupéré, puis analysé pour en extraire le texte, mis en minuscules (il faut donc enlever les entêtes, les balises...).
2. Le texte est ensuite découpé en mots, en découpant généralement selon les caractères non alphabétiques, mais en conservant les noms composés.
   On peut en profiter pour éliminer les mots inutiles (mots de liaison par exemple).
3. Se pose ensuite le problème des différentes variantes possibles d'un mot.
   Par exemple, *beau*, *belle*, *beaux* et *belles* sont 4 variantes du même adjectif. Pour les verbes, le problème est bien pire du fait de toutes les conjugaisons possibles...
   On doit donc effectuer ce qu'on appelle une ***lemmatisation*** des mots : on associe à chaque mot sa forme canonique. Ainsi, *beau*, *belle*, *beaux* et *belles* seront tous convertis en *beau*. On dit que *beau* est le ***lemme*** obtenu à partir de ces 4 formes. De même, *mangeront*, *mangeais* et *mangées* donneront le lemme *manger*.
4. Enfin, on doit compter le nombre de fois que l'on obtient chaque lemme.
   Il faut alors sauvegarder, pour chaque page, le décompte obtenu.

Exemple

Considérons par exemple la page HTML suivante :

```
<!DOCTYPE html>
<html lang="fr">
<head>
<meta charset="UTF-8" />
<title>Parlement du Royaume-Uni</title>
</head>
<body>
<h1>Parlement du Royaume-Uni</h1>
<p>Le <b>parlement britannique</b>, officiellement le <b>parlement du Royaume-Uni de
Grande-Bretagne et d'Irlande du Nord</b>, exerce le <a
href="/wiki/Pouvoir_l%C3%A9gislatif">pouvoir législatif</a> et le contrôle du gouvernement du
<a href="/wiki/Royaume-Uni">Royaume-Uni</a>.</p>
</body>
</html>
```

Texte brut obtenu :

```
parlement du royaume-uni
parlement du royaume-uni
le parlement britannique, officiellement le parlement du royaume-uni de grande-bretagne et
d'irlande du nord, exerce le pouvoir législatif et le contrôle du gouvernement du royaume-uni.
```

Conversion en mots et suppression des mots « inutiles » :

parlement royaume-uni parlement royaume-uni parlement britannique officiellement parlement royaume-uni grande-bretagne irlande nord exerce pouvoir législatif contrôle gouvernement royaume-uni

Lemmatisation possible :

parlement royaume-uni parlement royaume-uni parlement britannique officiel parlement royaume-uni grande-bretagne irlande nord exercer pouvoir législatif contrôler gouvernement royaume-uni

Décompte des mots :

```
parlement:4
royaume-uni:4
britannique:1
officiel:1
```

grande-bretagne:1
irlande:1
nord:1
exercer:1
pouvoir:1
législatif:1
contrôler:1
gouvernement:1

Quelques remarques sur la lemmatisation :

La méthode la plus simple pour lemmatiser est d'utiliser un dictionnaire.

Cette méthode n'est cependant pas parfaite, notamment parce qu'il y a des homonymes (est-ce que *mûre* se rapporte au fruit ou à l'adjectif ?). Appliquer à une phrase une analyse grammaticale préalable permet d'améliorer la pertinence de la lemmatisation, mais cela dépasse largement le cadre de cette SAÉ...

Notons enfin que la lemmatisation peut être plus ou moins poussée : on peut choisir par exemple de rattacher *beauté* à *beau*, puisqu'au fond le sens est le même. Voire même l'étendre à d'autres mots de sens similaire (*joli* par exemple), mais il s'agit alors d'analyse sémantique et plus de lemmatisation à proprement parler.

La recherche proprement dite (*à chaud*)

La recherche proprement dite doit se faire en temps réel, pour que l'utilisateur ait immédiatement son résultat. Il faut :

1. Convertir la requête en une liste de mots.
2. Convertir ces mots en lemmes.
3. Compter le nombre de fois qu'apparaît chaque lemme.
4. Comparer la requête et chacun des documents à partir du décompte de leurs lemmes.

Cela implique d'avoir au préalable chargé en mémoire le contenu des fichiers indexés.

◀ Généralités Aller à... Contraintes techniques ▶